



**INSTITUTO POLITÉCNICO
NACIONAL**



ESCUELA SUPERIOR DE CÓMPUTO

BASES DE DATOS

**PRÁCTICA 1: " MODELO ENTIDAD
RELACIÓN"**

**ALUMNA:
MOLINA ZAVALA ANGIE LALAINÉ**

**PROFESOR:
HURTADO AVILES GABRIEL**

GRUPO: 3BV1

**CIUDAD DE MÉXICO A 17 DE
SEPTIEMBRE DEL 2026**

OBJETIVO

Que usted analice las arquitecturas de los sistemas gestores de bases de datos a partir de su clasificación y de los diversos tipos de bases de datos, construya el entorno de trabajo que empleará durante todo el semestre (control de versiones y un sistema gestor ejecutado en un contenedor), sustente su investigación con literatura científica arbitrada y aplique lo anterior al modelado conceptual de un problema real. Toda la evidencia se entrega en un repositorio de Git. Esta práctica cubre la Unidad Temática I completa y, al mismo tiempo, establece la forma de trabajo del resto del curso. Se divide en cinco ejercicios: los dos primeros construyen el entorno técnico, el tercero y el cuarto sustentan la parte conceptual, y el quinto la aplica a un caso concreto. La entrega no es un archivo suelto: es un repositorio de Git donde quedará registrado cómo trabajó usted, no solo el resultado final.

EJERCICIO 3. INVESTIGACIÓN: QUÉ ES UNA BASE DE DATOS

Elabore un documento de entre cuatro y seis cuartillas que cubra los temas de la Unidad Temática I de su programa de estudios. No se admite copiar y pegar: todo lo que provenga de una fuente debe ir citado en el texto y referido al final.

Temas que debe cubrir:

1. Dato, información y base de datos. Incluya la definición formal de al menos dos autores distintos y compárelas.
2. Fundamentos de las bases de datos: qué problemas del enfoque de archivos resuelve un sistema gestor y por qué surgió.
3. Arquitectura ANSI-SPARC: origen, propósito y los tres esquemas que propone.
4. Independencia de datos, lenguajes de un sistema gestor y módulos componentes.
5. Tipos de bases de datos: relacionales, documentales, de clave-valor, de familias de columnas, de grafos y especializadas (series de tiempo, espaciales y vectoriales). Indique un caso de uso real para cada tipo.
6. Clasificación de los sistemas gestores: por modelo de datos, por número de usuarios, por número de sitios, por propósito y por licencia.
7. Bases de datos en flujos de trabajo de inteligencia artificial: qué papel juegan en el almacenamiento de conjuntos de entrenamiento, en la recuperación de información y en los sistemas de búsqueda por similitud.

EJERCICIO 3. INVESTIGACIÓN: QUÉ ES UNA BASE DE DATOS

1.-Conceptos Fundamentales

En el ámbito de la informática y el tratamiento de la información, es indispensable distinguir entre los conceptos de dato, información y base de datos. Un dato se define como una representación simbólica (numérica, alfabética, algorítmica, entre otras) de un atributo, variable o cualidad de una entidad. En su estado primario o desestructurado, los datos carecen de sentido contextual o valor semántico directo para la toma de decisiones.

Por otro lado, la información es el resultado del procesamiento, organización, estructuración e interpretación de un conjunto de datos dentro de un contexto determinado. La información otorga significado y reduce la incertidumbre del receptor.

Una base de datos es un conjunto estructurado y organizado de datos interrelacionados que se almacenan de manera persistente en soportes electrónicos, de modo que puedan ser accedidos, gestionados, consultados y actualizados de forma rápida, eficiente y concurrente por múltiples aplicaciones o usuarios.

- Definición de C. J. Date (2004):

"Una base de datos es una colección de datos persistentes utilizados por los sistemas de aplicaciones de una empresa determinada." Date enfatiza que una base de datos no es simplemente un conjunto de archivos aislados, sino un repositorio compartido y mantenido dinámicamente.

- Definición de Abraham Silberschatz, Henry F. Korth y S. Sudarshan (2014):

"Una base de datos es una colección de datos interrelacionados y un conjunto de programas para acceder a dichos datos (conocido como Sistema Gestor de Bases de Datos, SGBD). La colección de datos, que habitualmente se denomina base de datos, contiene información relevante para una empresa."

EJERCICIO 3. INVESTIGACIÓN: QUÉ ES UNA BASE DE DATOS

Comparación

Autor	C. J. Date (2004)	Silberschatz, Korth & Sudarshan (2014)
Enfoque Principal	Persistencia de datos y compartición dentro del contexto de la empresa.	Integración entre la estructura de datos y el software gestor (SGBD) para su acceso.
Perspectiva de Negocio	Datos persistentes utilizados de forma transversal por múltiples aplicaciones.	Contenido relevante e interrelacionado diseñado para dar soporte operativo.
Relación con el Software	Trata la base de datos como una entidad lógica diferenciada del sistema de gestión.	Fusiona conceptualmente la base de datos con el software de gestión para definir el entorno operacional.

EJERCICIO 3. INVESTIGACIÓN: QUÉ ES UNA BASE DE DATOS

2. Fundamentos de las Bases de Datos

Origen del Enfoque Tradicional de Archivos

Antes de la llegada de los Sistemas Gestores de Bases de Datos (SGBD), las organizaciones almacenaban y procesaban la información mediante el enfoque tradicional de archivos. En este esquema, cada departamento o aplicación desarrollaba sus propios programas en lenguajes como COBOL, FORTRAN o C, y creaba sus propios archivos independientes para almacenar datos específicos.

Problemas del Enfoque Tradicional

Este enfoque presentó serias limitaciones a medida que los volúmenes de datos y las necesidades operativas crecieron:

1. Redundancia e Inconsistencia de Datos: Al existir archivos independientes por cada aplicación, los mismos datos (como la dirección o el teléfono de un cliente) se duplicaban en múltiples archivos. Esto provocaba desperdicio de espacio de almacenamiento e inconsistencia cuando la información se actualizaba en un archivo pero no en los demás.
2. Dificultad en el Acceso a los Datos: Para responder a una nueva consulta no contemplada en el diseño inicial, se requería programar un nuevo software específico para procesar los archivos existentes.
3. Aislamiento de Datos: Debido a que los datos estaban dispersos en diferentes archivos estructurados con diversos formatos y lenguajes de programación, escribir nuevas aplicaciones para extraer datos combinados resultaba complejo.
4. Problemas de Anomalías en el Acceso Concurrente: Si múltiples usuarios o procesos intentaban actualizar simultáneamente el mismo archivo, la falta de coordinación provocaba pérdida de actualizaciones o corrupción de datos.
5. Anomalías de Seguridad y Privacidad: Resultaba difícil restringir el acceso a partes específicas de un archivo, ya que los permisos de seguridad se aplicaban a nivel global sobre el archivo completo.
6. Falta de Integridad: Las reglas de validación (restricciones de integridad) debían codificarse directamente en los programas de aplicación. Si las reglas cambiaban, se debían modificar todos los programas asociados.

EJERCICIO 3. INVESTIGACIÓN: QUÉ ES UNA BASE DE DATOS

Surgimiento de los SGBD

Un Sistema Gestor de Bases de Datos (SGBD) o Database Management System (DBMS) surgió a finales de la década de 1960 para actuar como una interfaz entre la base de datos, los usuarios y las aplicaciones. El SGBD abstrae la gestión física de los datos, garantizando la centralización del control, la reducción de la redundancia, la concurrencia segura y el cumplimiento estricto de restricciones de integridad y reglas de seguridad.

3. Arquitectura ANSI-SPARC

Origen y Propósito

En 1975, el Comité de Planificación y Estándares de Normas (SPARC) del Instituto Nacional Estadounidense de Estándares (ANSI) propuso un modelo conceptual de referencia denominado la Arquitectura ANSI-SPARC de tres niveles. El propósito principal de este estándar es lograr la independencia de datos, separando la vista de los usuarios finales de la forma en que los datos se estructuran lógicamente y se almacenan físicamente en el hardware.

Los Tres Niveles de la Arquitectura

1. Nivel Externo (Esquemas Externos o Vistas de Usuario):

- Es el nivel más cercano a los usuarios finales y programas de aplicación.
- Proporciona múltiples vistas externas personalizadas de la base de datos. Cada vista describe solo la parte de la base de datos que resulta relevante para un grupo o usuario específico, ocultando los datos que no les competen o a los que no tienen autorización.

2. Nivel Conceptual (Esquema Conceptual):

- Es el nivel intermedio de abstracción. Describe qué datos están almacenados en la base de datos y qué relaciones existen entre ellos para toda la organización.
- Contiene la estructura lógica global: entidades, atributos, relaciones, tipos de datos, operaciones de usuario y restricciones de integridad. No se preocupa por cómo se almacenan físicamente los datos en el disco.

3. Nivel Interno (Esquema Interno o Físico):

- Es el nivel más bajo de abstracción. Describe cómo se almacenan físicamente los datos en los dispositivos de almacenamiento secundario.
- Contiene la representación detallada de las estructuras de archivos, organización de registros, índices de búsqueda, punteros de direccionamiento, asignación de bloques de disco y algoritmos de compresión/criptación.

EJERCICIO 3. INVESTIGACIÓN: QUÉ ES UNA BASE DE DATOS

4. Independencia de Datos, Lenguajes y Módulos de un SGBD

Independencia de Datos

La arquitectura ANSI-SPARC facilita la independencia de datos, definida como la capacidad de modificar el esquema en un nivel sin tener que alterar el esquema del nivel inmediato superior. Existen dos tipos esenciales:

- **Independencia Física de Datos:** Es la capacidad de modificar el esquema interno (como reorganizar archivos en disco, cambiar estructuras de índices o agregar unidades de almacenamiento) sin necesidad de modificar el esquema conceptual ni los programas de aplicación existentes.
- **Independencia Lógica de Datos:** Es la capacidad de modificar el esquema conceptual (como añadir una nueva entidad o alterar atributos de una tabla) sin necesidad de reescribir las vistas externas existentes ni los programas de aplicación que no utilizan directamente los elementos modificados.

Lenguajes de un SGBD

Para interactuar con la base de datos, los SGBD proporcionan lenguajes especializados:

- **DDL (Data Definition Language / Lenguaje de Definición de Datos):** Utilizado por administradores de bases de datos (DBA) y diseñadores para definir, modificar o eliminar la estructura física y lógica de la base de datos (CREATE, ALTER, DROP, TRUNCATE). Genera el diccionario o catálogo de datos.
- **DML (Data Manipulation Language / Lenguaje de Manipulación de Datos):** Utilizado por usuarios o aplicaciones para consultar y modificar los datos almacenados (SELECT, INSERT, UPDATE, DELETE). Puede ser procedural (especifica qué datos se necesitan y cómo obtenerlos) o no procedural/declarativo (especifica qué datos se necesitan sin indicar el procedimiento explícito).
- **DCL (Data Control Language / Lenguaje de Control de Datos):** Permite administrar los permisos y la seguridad de acceso a los objetos de la base de datos (GRANT, REVOKE).
- **TCL (Transaction Control Language / Lenguaje de Control de Transacciones):** Gestiona las transacciones para mantener la consistencia e integridad de los datos (COMMIT, ROLLBACK, SAVEPOINT).

EJERCICIO 3. INVESTIGACIÓN: QUÉ ES UNA BASE DE DATOS

Módulos Componentes de un SGBD

Un SGBD moderno se divide en componentes funcionales estructurados:

1. Procesador de Consultas (Query Processor):

- Intérprete DDL: Convierte las sentencias DDL en tablas de metadatos almacenadas en el catálogo.
- Compilador DML: Traduce las sentencias DML en instrucciones ejecutables de bajo nivel.
- Optimizador de Consultas: Evalúa múltiples estrategias de ejecución para una consulta y selecciona el plan más eficiente con base en estadísticas.

2. Gestor de Almacenamiento (Storage Manager):

- Gestor de Memoria Intermedia (Buffer Manager): Administra la memoria caché en RAM para optimizar la transferencia de datos desde y hacia los discos.
- Gestor de Archivos (File Manager): Asigna espacio en disco y gestiona la estructura física donde se depositan los registros.
- Gestor de Transacciones (Transaction Manager): Garantiza que la ejecución de las operaciones cumpla las propiedades ACID (Atomicidad, Consistencia, Aislamiento y Durabilidad).
- Gestor de Concurrency (Concurrency Control Manager): Coordina la ejecución simultánea de transacciones mediante mecanismos de bloqueo o control por marcas de tiempo (timestamps).

EJERCICIO 3. INVESTIGACIÓN: QUÉ ES UNA BASE DE DATOS

5. Tipos de Bases de Datos y Casos de Uso Reales

Las bases de datos se han diversificado para responder a diversas necesidades de rendimiento, volumen, variedad y velocidad:

1. Relacionales (RDBMS): Almacenan datos en tablas organizadas en filas y columnas estructuradas, vinculadas mediante claves primarias y foráneas. Cumplen con ACID.
 - Caso de uso real: Sistema de contabilidad y procesamiento de transacciones financieras bancarias en JPMorgan Chase.
2. Documentales (NoSQL): Almacenan datos en documentos semiestructurados (JSON, BSON o XML). Ideales para esquemas flexibles y dinámicos.
 - Caso de uso real: Gestión del catálogo de productos y perfiles de usuario en eBay utilizando MongoDB.
3. Clave-Valor (NoSQL): Almacenan información en pares simples de clave única y valor asociado. Ofrecen tiempos de respuesta de muy baja latencia en lectura y escritura.
 - Caso de uso real: Gestión de carritos de compras y sesiones de usuario en tiempo real en Amazon utilizando Redis o DynamoDB.
4. Familias de Columnas (Wide-Column / Columnar): Organizan los datos por columnas en lugar de filas, optimizando lecturas de grandes volúmenes de datos analíticos.
 - Caso de uso real: Almacenamiento e ingesta de feeds de actividad y mensajes en tiempo real a escala masiva en Netflix utilizando Apache Cassandra.
5. De Grafos (Graph Databases): Modelan la información como nodos, bordes (relaciones) y propiedades. Diseñadas para consultar redes complejas y conexiones interdependientes.
 - Caso de uso real: Motor de recomendaciones de conexiones profesionales y prevención de fraude en LinkedIn utilizando Neo4j.

EJERCICIO 3. INVESTIGACIÓN: QUÉ ES UNA BASE DE DATOS

6. Clasificación de los Sistemas Gestores de Bases de Datos

Los SGBD se pueden clasificar con base en distintos criterios arquitectónicos y operativos:

- Por Modelo de Datos:
 - Relacionales (RDBMS): MySQL, PostgreSQL, Oracle Database, Microsoft SQL Server.
 - NoSQL / No Relacionales: MongoDB, Cassandra, Redis, Neo4j.
 - Multimodelo: ArangoDB, Couchbase, OrientDB (admiten múltiples modelos como documentos, grafos y clave-valor en un único motor).
- Por Número de Usuarios:
 - Monousuario: Diseñados para un solo usuario a la vez (ej. SQLite, Microsoft Access).
 - Multiusuario: Soportan acceso concurrente simultáneo de cientos o miles de usuarios (ej. PostgreSQL, Oracle Enterprise).
- Por Número de Sitios (Distribución):
 - Centralizados: La base de datos y el SGBD residen en un único equipo centralizado.
 - Distribuidos: Los datos están repartidos lógicamente en múltiples nodos o servidores interconectados en red. Pueden ser homogéneos (mismo SGBD en todos los nodos) o heterogéneos (distintos SGBD coordinados).
- Por Propósito:
 - Propósito General: Versátiles para diversas aplicaciones (ej. PostgreSQL, MySQL).
 - Propósito Especial u OLAP/Analíticos: Diseñados específicamente para procesamiento analítico de grandes volúmenes (Data Warehouses) o sistemas en tiempo real (ej. Snowflake, ClickHouse).
- Por Licencia:
 - Código Abierto (Open Source): PostgreSQL, MySQL (Community Edition), MariaDB.
 - Comerciales / Propietarios: Oracle Database, Microsoft SQL Server, IBM DB2.

EJERCICIO 3. INVESTIGACIÓN: QUÉ ES UNA BASE DE DATOS

6. Clasificación de los Sistemas Gestores de Bases de Datos

Los SGBD se pueden clasificar con base en distintos criterios arquitectónicos y operativos:

- Por Modelo de Datos:
 - Relacionales (RDBMS): MySQL, PostgreSQL, Oracle Database, Microsoft SQL Server.
 - NoSQL / No Relacionales: MongoDB, Cassandra, Redis, Neo4j.
 - Multimodelo: ArangoDB, Couchbase, OrientDB (admiten múltiples modelos como documentos, grafos y clave-valor en un único motor).
- Por Número de Usuarios:
 - Monousuario: Diseñados para un solo usuario a la vez (ej. SQLite, Microsoft Access).
 - Multiusuario: Soportan acceso concurrente simultáneo de cientos o miles de usuarios (ej. PostgreSQL, Oracle Enterprise).
- Por Número de Sitios (Distribución):
 - Centralizados: La base de datos y el SGBD residen en un único equipo centralizado.
 - Distribuidos: Los datos están repartidos lógicamente en múltiples nodos o servidores interconectados en red. Pueden ser homogéneos (mismo SGBD en todos los nodos) o heterogéneos (distintos SGBD coordinados).
- Por Propósito:
 - Propósito General: Versátiles para diversas aplicaciones (ej. PostgreSQL, MySQL).
 - Propósito Especial u OLAP/Analíticos: Diseñados específicamente para procesamiento analítico de grandes volúmenes (Data Warehouses) o sistemas en tiempo real (ej. Snowflake, ClickHouse).
- Por Licencia:
 - Código Abierto (Open Source): PostgreSQL, MySQL (Community Edition), MariaDB.
 - Comerciales / Propietarios: Oracle Database, Microsoft SQL Server, IBM DB2.

EJERCICIO 3. INVESTIGACIÓN: QUÉ ES UNA BASE DE DATOS

7. Bases de Datos en Flujos de Trabajo de Inteligencia Artificial

Almacenamiento de Conjuntos de Entrenamiento

En las etapas iniciales de la IA y el Aprendizaje Automático (Machine Learning), las bases de datos relacionales y documentales actúan como el repositorio centralizado para curar, versionar y almacenar grandes volúmenes de datos tabulares, textuales y metadatos. Garantizan la trazabilidad, limpieza e integridad de los datos de entrenamiento (training datasets), permitiendo la extracción eficiente por lotes mediante canalizaciones (pipelines) de datos.

Recuperación de Información y RAG

Con el auge de los Modelos de Lenguaje de Gran Escala (Large Language Models, LLM), las bases de datos juegan un papel clave en la arquitectura de Generación Aumentada por Recuperación (Retrieval-Augmented Generation, RAG). En un flujo RAG, los documentos organizacionales se almacenan y segmentan. Ante la consulta de un usuario, el SGBD recupera la información contextual más relevante y precisa para inyectarla en la solicitud (prompt) enviada al modelo de IA, evitando alucinaciones y garantizando privacidad de datos corporativos.

Sistemas de Búsqueda por Similitud

Las bases de datos vectoriales representan un elemento central en los flujos de IA modernos. Los datos no estructurados (textos, imágenes, audio) se transforman en vectores de números flotantes de alta dimensión (embeddings) mediante modelos de aprendizaje profundo.

Estas bases de datos utilizan algoritmos de indexación vectorial aproximada (Approximate Nearest Neighbor, ANN) como HNSW (Hierarchical Navigable Small World) o IVF (Inverted File Index) para calcular distancias métricas (como la similitud del coseno o la distancia euclidiana). Esto permite realizar búsquedas por similitud semántica en milisegundos, impulsando sistemas de recomendación, motores de búsqueda contextual y asistentes conversacionales inteligentes.

REFERENCIAS

- Grupo de Estudio ANSI/X3/SPARC sobre Sistemas de Gestión de Bases de Datos. (1975). Informe interino 75-02-08. ACM SIGMOD Record, 7(2), 1-139.
- Date, C. J. (2004). Introducción a los sistemas de bases de datos (8.^a ed.). Pearson Addison-Wesley.
- Elmasri, R., y Navathe, S. B. (2016). Fundamentos de sistemas de bases de datos (7.^a ed.). Pearson.
- Garcia-Molina, H., Ullman, J. D., y Widom, J. (2014). Sistemas de bases de datos: El libro completo (2.^a ed.). Pearson.
- Silberschatz, A., Korth, H. F., y Sudarshan, S. (2014). Fundamentos de bases de datos (6.^a ed.). McGraw-Hill Education.